


0.1 Giới thiệu chương

Chương này trình bày chi tiết phương pháp đề xuất cùng toàn bộ thiết lập thực nghiệm dùng để kiểm chứng. Trước hết, mục 0.2 mô tả bộ dữ liệu FECGSYNDB và chiến lược chia tập theo hướng độc lập đối tượng; mục 0.3 trình bày quy trình tiền xử lý tín hiệu. Tiếp theo, mục 0.4 trình bày kiến trúc mô hình đề xuất KAN-WNETR. Mục 0.5 trình bày hàm mất mát và cấu hình huấn luyện, còn mục 0.6 trình bày phương pháp đánh giá gồm thuật toán phát hiện QRS và các nhóm chỉ số định lượng. Kết quả thực nghiệm tương ứng được trình bày ở Chương ??.

0.2 Bộ dữ liệu FECGSYNDB

Dữ liệu huấn luyện mô hình được lấy từ PhysioNet - Fetal ECG Synthetic Database (FECGSYNDB) [1]. Đây là một cơ sở dữ liệu mô phỏng tín hiệu điện tâm đồ thai và mẹ (NI-FECG/MECG) sử dụng mô phỏng từ công cụ FECGSYN, được xây dựng để phục vụ nghiên cứu phân tách và trích xuất fECG một cách có thể tái lập (reproducible research). Dữ liệu này được cung cấp công khai và thường dùng làm benchmark trong các nghiên cứu về thuật toán lọc và học máy cho fECG.



Hình 0.1: Hình chiếu bên (a) và nhìn từ trên (b). Vị trí tim thai (cầu nhỏ, màu xanh) và tim mẹ (cầu lớn, màu đỏ) được thể hiện.

Dữ liệu mô phỏng được tạo ra cho 10 thai kỳ khác nhau với các điều kiện sinh lý đa dạng. Mỗi lần mô phỏng tạo ra hỗn hợp tín hiệu bao gồm thành phần fECG, MEGC và các tín hiệu nhiễu khác. Mỗi tín hiệu trong dataset có độ dài 5 phút, tần số lấy mẫu 250 Hz và độ phân giải 16 bit, và được mô phỏng trên 34 kênh tín hiệu (32 kênh maECG và 2 kênh mECG chuẩn).

Dataset được tổ chức thành nhiều ngữ cảnh sinh lý khác nhau, bao gồm:

- **Baseline:** tín hiệu bung hỗn hợp không nhiễu và không biến cố.

- **C0:** baseline kèm nhiễu.
- **C1:** chuyển động thai + nhiễu.
- **C2:** thay đổi nhịp tim mẹ/nhịp tim thai (tăng hoặc giảm) + nhiễu.
- **C3:** co tử cung + nhiễu.
- **C4:** nhịp ngoại tâm thu ở mẹ hoặc thai + nhiễu.
- **C5:** song thai (tín hiệu NI-FECG bổ sung) + nhiễu.

Sự đa dạng này đặc biệt quan trọng vì nó mô phỏng các tình huống sinh lý và bệnh lý có thể gây biến dạng hoặc che lấp fECG trong thực tế, từ đó tạo điều kiện để mô hình học được các đặc trưng mạnh (robust features). Mỗi trường hợp được mô phỏng ở 5 mức SNR khác nhau (0, 3, 6, 9 và 12 dB) và 5 lần lặp lại để tăng tính đa dạng và khả năng kiểm định thuật toán. Việc thay đổi SNR đóng vai trò quan trọng trong huấn luyện mô hình deep learning vì nó giúp tăng khả năng tổng quát hóa (generalization) khi xử lý tín hiệu fECG biên độ thấp.

0.2.1 Chiến lược chia dữ liệu

Về chiến lược chia dữ liệu, tín hiệu từ đối tượng thứ 10 được dùng làm tập kiểm tra (test set), nhằm đảm bảo đánh giá khả năng tổng quát hóa theo subject-independent setting — tức là mô hình chưa từng thấy dữ liệu của đối tượng này trong quá trình huấn luyện. Đây là cách chia phù hợp khi so sánh với các phương pháp tiên tiến khác. Trong huấn luyện, chỉ sử dụng các kênh maECG số 11, 19, 22 và 25 từ các đối tượng.

0.3 Tiền xử lý

Tín hiệu maECG được lấy mẫu ở tần số $f_s = 250$ Hz. Để loại bỏ các thành phần không thuộc dải tần sinh lý của ECG, một bộ lọc thông dải (bandpass filter) trong khoảng 3–90 Hz được áp dụng. Giới hạn dưới 3 Hz giúp loại bỏ trôi nền (baseline wander) và nhiễu chuyển động chậm, trong khi giới hạn trên 90 Hz loại bỏ nhiễu tần số cao như nhiễu cơ (EMG) và nhiễu điện tử, đồng thời vẫn bảo toàn các thành phần hình thái quan trọng của ECG, đặc biệt là phức bộ QRS.

Sau bước lọc, tín hiệu được chia thành các cửa sổ có độ dài 992 mẫu (tương đương khoảng 3.97 giây). Việc phân đoạn này nhằm chuẩn hóa kích thước đầu vào của mạng và giúp mô hình học được đặc trưng theo thời gian cục bộ.

0.3.1 Chuẩn hóa tín hiệu

Để tăng tính ổn định trong quá trình huấn luyện và đảm bảo khả năng thích nghi với nhiều mức biên độ khác nhau, tín hiệu được chuẩn hóa dựa trên độ lệch chuẩn của tín hiệu nhiễu. Gọi y là tín hiệu maECG nhiễu (đầu vào), x là tín hiệu fECG sạch (ground truth), và σ_y là độ lệch chuẩn của y , khi đó:

$$\hat{x} = \frac{x}{\sigma_y}, \quad \hat{y} = \frac{y}{\sigma_y} \quad (1)$$

Trong đó $\hat{y}$ là tín hiệu đầu vào đã chuẩn hóa được đưa vào mạng và $\hat{x}$ là tín hiệu mục tiêu tương ứng.

Sau khi dự đoán, biên độ tín hiệu được khôi phục bằng cách nhân lại với σ_y :

$$x_{\text{denoised}} = \tilde{x} \cdot \sigma_y \quad (2)$$

Quy trình tiền xử lý tổng thể bao gồm: lấy mẫu ở 250 Hz, lọc thông dải 3–90 Hz, phân đoạn cửa sổ 992 mẫu và chuẩn hóa theo độ lệch chuẩn của tín hiệu nhiễu. Quy trình này giúp cải thiện độ ổn định số, tăng khả năng hội tụ và nâng cao hiệu năng của mô hình trong bài toán trích xuất fECG.

0.4 Mô hình đề xuất KAN-WNETR

0.4.1 Ý tưởng tổng thể

Như đã phân tích ở Chương ??, bài toán trích xuất fECG từ tín hiệu maECG đơn kênh phải đối mặt với hai thách thức cốt lõi: tỷ số tín hiệu trên nhiễu (SNR) rất thấp của fECG so với mECG, và sự chồng lấp phổ thời–tần giữa hai thành phần — đặc biệt tại các thời điểm phức bộ QRS mẹ và thai trùng nhau. Kiến trúc W-NETR [2] đã cho thấy hiệu quả nhờ cơ chế hai nhánh kết hợp khử đặc trưng mECG; tuy nhiên, khối MLP/FFN bên trong Transformer encoder — bộ phận chịu trách nhiệm biến đổi phi tuyến theo token — vẫn dùng hai lớp tuyến tính xen kẽ hàm kích hoạt GELU cố định ($W_2 \text{GELU}(W_1 z + b_1) + b_2$), hạn chế khả năng thích nghi với các dạng phi tuyến phức tạp trong tín hiệu sinh học.

Ý tưởng cốt lõi của đề tài là **giữ nguyên macro-architecture chữ W của W-NETR** (hai nhánh + cơ chế khử đặc trưng mECG) và **chỉ thay khối MLP/FFN trong mọi Transformer encoder block bằng khối FasterKAN** — một biến thể hiệu quả của Kolmogorov–Arnold Network (KAN) [3] sử dụng hàm cơ sở RBF thay cho B-spline truyền thống. Phép can thiệp đúng vào MLP/FFN là hợp lý vì

đây là bộ phận duy nhất thực hiện biến đổi phi tuyến theo kênh (channel-mixing) trên embedding của từng token sau khi attention đã trộn thông tin giữa các token; nâng cấp bộ phận này bằng hàm kích hoạt học được giúp tăng năng lực biểu diễn phi tuyến mà không làm thay đổi cách mô hình học phụ thuộc xa qua Multi-Head Self-Attention.

0.4.2 Kiến trúc nền W-NETR

W-NETR [2] dùng hai nhánh UNETR 1D chạy song song: nhánh phải tái tạo/trích xuất **fECG**, nhánh trái tái tạo **mECG**. Mỗi nhánh có cấu trúc UNETR gồm encoder Transformer ($L = 12$ lớp) và decoder CNN với các skip-connection tại 4 mức tương ứng đầu ra của lớp encoder thứ $\{3, 6, 9, 12\}$.

Khác biệt cốt lõi của W-NETR so với một UNETR đơn lẻ là cơ chế **khử đặc trưng mECG** (mECG feature elimination). Tại mỗi mức skip-connection $s \in \{3, 6, 9, 12\}$, đặc trưng nhánh mECG được trừ khỏi đặc trưng nhánh fECG **trước khi** đưa vào decoder CNN của nhánh fECG, kèm hàm tanh để chặn biên và ổn định:

$$\tilde{z}_s^{(f)} = \tanh(z_s^{(f)} - z_s^{(m)}), \quad s \in \{3, 6, 9, 12\}, \quad (3)$$

trong đó $z_s^{(f)}$ và $z_s^{(m)}$ lần lượt là đầu ra encoder tại lớp thứ s của nhánh fECG và nhánh mECG. Phép trừ này chỉ áp dụng **một chiều** (từ nhánh mECG sang nhánh fECG); nhánh mECG giữ skip-connection nguyên bản không bị can thiệp. Trực giác là: mô hình học đồng thời hai biểu diễn, sử dụng đặc trưng mECG như “mẫu nền” để khử thành phần mẹ khỏi nhánh fECG ngay trong không gian đặc trưng.

0.4.3 KAN-ViT: thay MLP/FFN bằng KAN trong encoder block

Ý tưởng KAN-ViT [4] giữ nguyên cơ chế Multi-Head Self-Attention (MSA) cùng cấu trúc residual và Layer Normalization (LN), chỉ thay khối MLP/FFN bằng khối KAN:

$$z'_\ell = \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1}, \quad (4)$$

$$z_\ell = \text{KAN}(\text{LN}(z'_\ell)) + z'_\ell. \quad (5)$$

Attention vẫn đảm nhận việc học quan hệ giữa các token (toàn cục), còn nhánh phi tuyến “theo token” được tăng năng lực biểu diễn nhờ hàm kích hoạt học được của KAN.

Trong Transformer, MSA quyết định cách “gán trọng số” để trộn thông tin giữa các token, còn MLP quyết định mức độ biến đổi phi tuyến hậu attention. Can thiệp vào MLP là hợp lý vì đây là nơi mô hình “nắn” đặc trưng phi tuyến theo kênh;

KAN cung cấp phi tuyến có thể học trực tiếp trên mỗi cạnh, tiềm năng tốt hơn so với phép ánh xạ cố định $W_2 \sigma(W_1 \cdot)$ khi đối mặt với các dạng phi tuyến và nhiễu khó tuyến tính hoá trong tín hiệu sinh học.

Dù KAN-ViT được đề xuất ban đầu cho ảnh 2D, bản chất “Transformer encoder + FFN” là bất biến theo miền dữ liệu. Với tín hiệu 1D, mỗi token ứng với một patch trên trục thời gian; attention học phụ thuộc xa (long-range dependencies) giữa các đoạn tín hiệu; và KAN-FFN tăng năng lực biến đổi phi tuyến trên embedding của từng token — đặc biệt hữu ích khi biên độ fECG thay đổi theo đối tượng/lead, khi tồn tại artifact cục bộ mạnh, và khi cần bảo toàn hình thái sóng P/QRS/T nhạy cảm với phi tuyến và tỷ lệ.

0.4.4 Biến thể FasterKAN: hàm cơ sở RBF và nhánh SiLU residual

Thay vì sử dụng KAN gốc với tham số hoá B-spline [3] — vốn tồn kém về bộ nhớ và chi phí tính do phải duy trì bộ hệ số spline trên lưới mịn — đề tài chọn biến thể **FasterKAN** [5] sử dụng hàm cơ sở dạng RBF (Reflectional Switch Function), cho phép tính toán nhanh hơn đáng kể trong khi vẫn giữ được tính chất “hàm kích hoạt được trên cạnh” của KAN.

Hàm cơ sở RBF. Cho một lưới đều gồm G điểm $\{g_k\}_{k=1}^G$ trên đoạn $[-2, 2]$, FasterKAN định nghĩa hàm cơ sở tại mỗi điểm lưới g_k :

$$\phi_k(x) = 1 - \tanh^2\left(\frac{x - g_k}{h}\right) = \operatorname{sech}^2\left(\frac{x - g_k}{h}\right), \quad (6)$$

trong đó $h = 0,33$ là tham số bề rộng (denominator). Hàm ϕ_k có dạng “chuông” (chính là đạo hàm của tanh), tập trung quanh điểm lưới g_k và suy giảm nhanh khi ra xa. Mỗi nơ-ron đầu vào có chiều d được khai triển thành $d \times G$ đặc trưng cơ sở $\phi_k(x_j)$, sau đó được chiếu tuyến tính bằng ma trận trọng số W_s (SplineLinear, không có bias, khởi tạo Xavier-uniform) để tạo đầu ra:

$$\text{KAN}_{\text{RBF}}(\mathbf{x}) = W_s \Phi_{\text{RBF}}(\text{LN}(\mathbf{x})), \quad (7)$$

trong đó Φ_{RBF} ký hiệu phép áp dụng hàm (6) trên toàn bộ lưới, và LN là Layer Normalization nội bộ của mỗi lớp FasterKAN.


Nhánh SiLU residual. Để ổn định tối ưu hoá và tăng tốc hội tụ, FasterKAN bổ sung một nhánh residual song song sử dụng hàm kích hoạt SiLU (Sigmoid Linear Unit):

$$\text{FasterKANLayer}(\mathbf{x}) = \underbrace{W_s \Phi_{\text{RBF}}(\text{LN}(\mathbf{x}))}_{\text{nhánh cơ sở RBF}} + \underbrace{W_b \text{SiLU}(\text{LN}(\mathbf{x}))}_{\text{nhánh residual SiLU}}, \quad (8)$$

trong đó W_b là ma trận tuyến tính có bias. Nhánh SiLU cung cấp một đường “bypass” ổn định, cho phép nhánh RBF tập trung vào việc học các chi tiết cục bộ phi tuyến mà phần tuyến tính + SiLU chưa nắm bắt được.

Cấu trúc khối FasterKAN trong encoder. Trong mô hình KAN-WNETR, mỗi khối FasterKAN gồm 2 lớp FasterKANLayer xếp chồng: $[d_{\text{hidden}} \rightarrow d_{\text{mlp}} \rightarrow d_{\text{hidden}}]$ (tương tự cấu trúc 2 lớp “expand-compress” của MLP gốc), kèm Dropout. Với cấu hình thực nghiệm $d_{\text{hidden}} = 256$, $d_{\text{mlp}} = 512$, $G = 4$ điểm lưới, mỗi FasterKANLayer bao gồm: (1) Layer Normalization nội bộ trên đầu vào, (2) nhánh RBF ($d_{\text{in}} \times G \rightarrow d_{\text{out}}$), và (3) nhánh SiLU residual ($d_{\text{in}} \rightarrow d_{\text{out}}$). So với MLP gốc (chỉ có 1 Layer Normalization ở mức Transformer block), đường KAN có thêm 1 LN nội bộ ở mỗi lớp, giúp ổn định huấn luyện khi sử dụng hàm kích hoạt phi truyền thống.

0.4.5 Tích hợp KAN vào W-NETR: kiến trúc KAN-WNETR



Hình 0.2: Mô hình KAN-WNETR đề xuất: tín hiệu ECG bụng mẹ (maECG) được xử lý qua kiến trúc hai nhánh UNETR 1D — nhánh trái tái tạo mECG, nhánh phải trích xuất fECG. Các đường màu đỏ biểu diễn phép trừ đặc trưng mECG khỏi nhánh fECG tại 4 mức skip-connection ($s \in \{3, 6, 9, 12\}$) của decoder CNN, kèm hàm tanh sau phép trừ. Khối MLP/FFN trong mọi Transformer encoder block được thay thế bằng khối FasterKAN (cơ sở RBF + nhánh SiLU residual).

Nguyên tắc tích hợp. KAN-WNETR giữ nguyên toàn bộ macro-architecture của W-NETR: patchify 1D (kích thước patch = 16) kèm positional embedding dạng tích chập; $L = 12$ lớp Transformer encoder; skip-connection từ $\{3, 6, 9, 12\}$ sang decoder CNN; hai nhánh (mECG và fECG) cùng cơ chế khử đặc trưng mECG theo công thức (3). Điểm thay đổi duy nhất là **thay khối MLP trong mọi Transformer encoder block bằng khối FasterKAN** (mục 0.4.4).

Khối encoder sau thay thế. Với mỗi encoder block ℓ ($\ell = 1, \dots, 12$) ở từng nhánh:

$$z'_\ell = \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1}, \quad (9)$$

$$z_\ell = \text{FasterKAN}(\text{LN}(z'_\ell)) + z'_\ell, \quad (10)$$

trong đó FasterKAN là khối 2 lớp FasterKANLayer theo công thức (8).

Tại 4 mức skip-connection $s \in \{3, 6, 9, 12\}$, phép khử đặc trưng mECG được áp dụng **một chiều** — chỉ can thiệp vào nhánh fECG, nhánh mECG giữ skip nguyên bản:

$$\tilde{z}_s^{(f)} = \tanh(z_s^{(f)} - z_s^{(m)}), \quad s \in \{3, 6, 9, 12\}. \quad (11)$$

Đặc trưng $\tilde{z}_s^{(f)}$ sau đó được đưa vào khối upsampling tương ứng của decoder CNN nhánh fECG.

0.4.6 Phân tích thiết kế và kỳ vọng

Thay MLP bằng FasterKAN là thay đúng bộ phận chịu trách nhiệm biến đổi phi tuyến theo token (channel-mixing) và tính chỉnh embedding sau attention, trong khi vẫn giữ nguyên MSA để học phụ thuộc xa. Cụ thể, hàm kích hoạt RBF học được trên lưới cho phép mỗi lớp FasterKAN tự thích nghi với dạng phi tuyến cục bộ của tín hiệu — khác với MLP gốc chỉ dùng hàm GELU cố định cho mọi đầu vào. Do đó, KAN-WNETR kỳ vọng: (i) bảo toàn hình thái fECG (sóng P/QRS/T) tốt hơn trong điều kiện nhiễu biến thiên; (ii) giảm nhầm lẫn khi mECG và fECG chồng lấp tại thời điểm QRS; (iii) tăng ổn định khi biên độ và lead thay đổi nhờ khả năng tự điều chỉnh của hàm kích hoạt RBF.

0.4.7 Tổng hợp đóng góp kiến trúc

- W-NETR giải quyết bài toán tách nguồn theo hướng hai nhánh kết hợp khử đặc trưng mECG tại 4 mức skip-connection trong không gian biểu diễn.
- ViT/Transformer encoder cung cấp ngữ cảnh toàn cục nhờ MSA, khắc phục receptive field hạn chế của CNN.
- FasterKAN thay MLP trong encoder block, tăng năng lực phi tuyến token-wise nhờ hàm cơ sở RBF học được kết hợp nhánh SiLU residual, giúp cải thiện khả năng mô hình hoá biến thiên phi tuyến trong tín hiệu mECG và bảo toàn hình thái fECG.
- KAN-WNETR kết hợp bốn thành phần: **ngữ cảnh toàn cục (MSA) + phi tuyến học được (FasterKAN) + khử đặc trưng mẹ (cơ chế W) + tái tạo chi tiết cục bộ (decoder CNN)**.

0.5 Hàm mất mát và cấu hình huấn luyện

0.5.1 Hàm mất mát Huber (Huber Loss)

Trong bài toán hồi quy tín hiệu (ví dụ tái tạo fECG), việc lựa chọn hàm mất mát ảnh hưởng trực tiếp đến độ vững của quá trình huấn luyện:

- MSE (L2): nhạy sai số nhỏ, tối ưu mượt, nhưng bị outlier chi phối mạnh.
- MAE (L1): bền với outlier nhưng gradient không mượt quanh 0.
- Huber: kết hợp ưu điểm hai loại $\Rightarrow$ lý do được chọn cho bài toán tái tạo fECG (nhiều đoạn nhiễu đột biến).

Hàm mất mát Huber thường được sử dụng để tăng tính *robust* trước các điểm ngoại lai (outliers) hoặc các đoạn nhiễu đột biến. Huber loss kết hợp ưu điểm của MSE và MAE: với sai số nhỏ, hàm phạt theo bình phương (giúp tối ưu mượt và nhạy với sai số nhỏ), còn với sai số lớn, hàm phạt tuyến tính (giảm ảnh hưởng của outlier).

Gọi residual (sai số) tại mẫu i là

$$r_i = y_i - \hat{y}_i, \quad (12)$$

trong đó y_i là giá trị mục tiêu (ground truth) và $\hat{y}_i$ là giá trị dự đoán của mô hình. Khi đó, Huber loss với ngưỡng $\delta > 0$ được định nghĩa như sau:

$$\mathcal{L}_\delta(r_i) = \begin{cases} \frac{1}{2}r_i^2, & |r_i| \leq \delta, \\ \delta \left(|r_i| - \frac{1}{2}\delta \right), & |r_i| > \delta. \end{cases} \quad (13)$$

Đạo hàm theo r_i (gradient) có dạng:

$$\frac{\partial \mathcal{L}_\delta}{\partial r_i} = \begin{cases} r_i, & |r_i| \leq \delta, \\ \delta \operatorname{sign}(r_i), & |r_i| > \delta, \end{cases} \quad (14)$$

cho thấy gradient bị chặn trong khoảng $[-\delta, \delta]$ khi sai số lớn, nhờ đó hạn chế việc một số ít điểm nhiễu mạnh chi phối quá trình cập nhật tham số.

Với một cửa sổ tín hiệu có T mẫu, loss tổng quát thường lấy trung bình:

$$\mathcal{L} = \frac{1}{T} \sum_{i=1}^T \mathcal{L}_\delta(r_i). \quad (15)$$

Tham số δ điều khiển mức độ gần MSE hoặc MAE: δ càng lớn thì loss gần MSE hơn; δ càng nhỏ thì loss gần MAE hơn.

0.5.2 Cấu hình huấn luyện

Để bảo đảm khả năng tái lập, phần này công bố đầy đủ cấu hình kiến trúc, hàm mất mát, thuật toán tối ưu và môi trường thực nghiệm. Mô hình được huấn luyện theo hai giai đoạn: tiền huấn luyện (pretrain) trên dữ liệu mô phỏng FECGSYNDB, sau đó tinh chỉnh (finetune) trên dữ liệu thực ADFECGDB.

Bảng 1: Cấu hình kiến trúc và siêu tham số huấn luyện của mô hình KAN-WNETR (biến thể `kan_wnetr_base`, $\approx 38,87\text{M}$ tham số).

Tham số	Giá trị
<i>Kiến trúc (KAN-ViT encoder)</i>	
Kích thước ẩn (<code>hidden_size</code>)	256
Chiều FFN (<code>mlp_dim</code>)	512
Số đầu attention (<code>num_heads</code>)	8
Số block encoder (<code>num_layers</code>)	12
Số điểm lưới RBF (<code>num_grids</code>)	4
Nhánh SiLU residual (<code>use_base_update</code>)	Bật
Patch size	16
Feature size	16
Dropout	0.2
<i>Huấn luyện (giai đoạn tinh chỉnh ADFECGDB)</i>	
Optimizer	AdamW (<code>weight_decay</code> = 0.01)
Tốc độ học	2×10^{-5}
Scheduler	Cosine annealing + warmup
Số epoch	150
Batch size	64
Số workers	4
Hàm mất mát	Tổ hợp (Huber + SSIM)

Thuật toán tối ưu. Mô hình được tối ưu bằng AdamW với các tham số mặc định của PyTorch ($\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$) và `weight_decay` = 0.01, learning rate 2×10^{-5} ở giai đoạn tinh chỉnh. Lịch học áp dụng cosine annealing kèm giai đoạn warmup. Batch size được chọn ở mức 64 để cân bằng giữa hiệu quả tính toán và độ nhiễu của gradient; do batch size tương tác mạnh với learning rate, mọi thay đổi batch size đều kéo theo việc hiệu chỉnh lại learning rate và/hoặc mức điều chuẩn.

- Phần cứng huấn luyện: GPU (ví dụ RTX 3060 12GB), RAM, CPU.
- Thư viện: PyTorch, MONAI (UnetrPrUpBlock/UnetrUpBlock), wfdb, scipy, numpy.

0.6 Phương pháp đánh giá

0.6.1 Phát hiện QRS

Thuật toán Pan-Thompkins là một trong những thuật toán phổ biến nhất để phát hiện phức hệ QRS và đỉnh R của tín hiệu ECG **panRealTimeQRSDetection1985**. Thuật toán này sử dụng các đặc trưng tín hiệu như biên độ, độ dốc và độ rộng của cửa sổ tích phân để xác định phức bộ QRS. Về tổng thể, thuật toán chia ra gồm 2 bước chính: (1) tiền xử lý tín hiệu và (2) đưa ra quyết định phát hiện. Chi tiết các bước của thuật toán được tóm tắt như sau:

0.6.1.1 Lọc thông dải (Band-pass)

Gọi tín hiệu ECG rời rạc là $x[n]$, với tần số lấy mẫu f_s . Mục tiêu là giữ dải tần chứa QRS (thường khoảng 5–15 Hz), khử trôi nền và nhiễu cao tần:

$$y_{bp}[n] = x[n] * h_{lp}[n] * h_{hp}[n]. \quad (16)$$

0.6.1.2 Đạo hàm

Nhằm nhấn mạnh sườn dốc lớn của QRS, phép đạo hàm được áp dụng lên tín hiệu, Sóng T và P sẽ bị yếu đi do độ dốc nhỏ.

$$y_d[n] = \frac{1}{8T} (2y_{bp}[n] + y_{bp}[n-1] - y_{bp}[n-3] - 2y_{bp}[n-4]), \quad (17)$$

trong đó $T = 1/f_s$.

0.6.1.3 Bình phương

Làm mọi giá trị dương và tăng trọng số cho biên độ lớn:

$$y_s[n] = (y_d[n])^2. \quad (18)$$

0.6.1.4 Tích phân cửa sổ trượt

Lấy đặc trưng năng lượng theo bề rộng QRS:

$$y_{mwi}[n] = \frac{1}{N} \sum_{i=0}^{N-1} y_s[n-i], \quad N \approx 0.15 f_s. \quad (19)$$

0.6.1.5 Phát hiện đỉnh bằng ngưỡng thích nghi

Tại mỗi đỉnh ứng viên P trên y_{mwi} , cập nhật ước lượng đỉnh tín hiệu và nhiễu:

$$SPKI \leftarrow 0.125 P + 0.875 SPKI, \quad (20)$$

$$NPKI \leftarrow 0.125 P + 0.875 NPKI, \quad (21)$$

(tùy theo P được phân loại là tín hiệu hay nhiễu), rồi đặt ngưỡng:

$$THR_I = NPKI + 0.25 (SPKI - NPKI). \quad (22)$$

Nếu khoảng RR hiện tại quá dài (thường $> 1.66 RR_{avg}$), thuật toán *search-back* sẽ tìm lại đỉnh bị bỏ sót.

Sau khi xác nhận một QRS, vị trí đỉnh R được lấy là cực đại cục bộ của tín hiệu đã lọc (hoặc ECG gốc) trong một cửa sổ lân cận quanh vị trí QRS (ví dụ ± 75 ms).

0.6.2 Chỉ số đánh giá

0.6.2.1 Nhóm chỉ số phát hiện fECG (Precision/Recall/F1/Accuracy)

Xét bài toán phát hiện (ví dụ phát hiện đỉnh R của fECG) như một bài toán phân loại nhị phân. Gọi: TP (true positives), FP (false positives), FN (false negatives), TN (true negatives). Khi đó các chỉ số được định nghĩa:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (23)$$

$$F1 = \frac{2 \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 TP}{2 TP + FP + FN}. \quad (24)$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}. \quad (25)$$

0.6.2.2 Nhóm chỉ số chất lượng tín hiệu (PSNR/SSIM/MSE)

Gọi $x[n]$ là fECG tham chiếu (ground truth) và $\hat{x}[n]$ là fECG được trích xuất, với $n = 1, \dots, N$. Sai số bình phương trung bình (MSE) được định nghĩa:

$$\text{MSE}(x, \hat{x}) = \frac{1}{N} \sum_{n=1}^N (x[n] - \hat{x}[n])^2. \quad (26)$$

Tỷ số đỉnh-tập (PSNR, đơn vị dB) được tính từ MSE:

$$\text{PSNR}(x, \hat{x}) = 10 \log_{10} \left(\frac{\text{MAX}_x^2}{\text{MSE}(x, \hat{x})} \right) = 20 \log_{10} \left(\frac{\text{MAX}_x}{\sqrt{\text{MSE}(x, \hat{x})}} \right), \quad (27)$$

trong đó MAX_x là biên độ cực đại theo dải động đã chọn (ví dụ $\text{MAX}_x = 1$ nếu tín hiệu đã chuẩn hoá về $[-1, 1]$).

Chỉ số tương đồng cấu trúc (SSIM) giữa hai tín hiệu (tính trên một cửa sổ, hoặc trung bình trên các cửa sổ trượt) được cho bởi:

$$\text{SSIM}(x, \hat{x}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)}, \quad (28)$$

với $\mu_x, \mu_{\hat{x}}$ là trung bình; $\sigma_x^2, \sigma_{\hat{x}}^2$ là phương sai; $\sigma_{x\hat{x}}$ là hiệp phương sai. Các hằng số ổn định thường đặt $C_1 = (K_1L)^2$, $C_2 = (K_2L)^2$, trong đó L là dải động và $K_1, K_2 \ll 1$.

0.6.2.3 Sai số ước lượng nhịp tim thai (FHR error)

Ngoài các chỉ số chất lượng tín hiệu và phát hiện fQRS nêu trên, đề tài bổ sung chỉ số sai số ước lượng nhịp tim thai (FHR) vì hệ thống theo dõi thời gian thực (Chương ??) lấy FHR làm đầu ra lâm sàng chính.

Quy trình ước lượng FHR từ tín hiệu fECG đã trích xuất gồm các bước sau. Trước hết, tín hiệu fECG được đưa qua một pipeline phát hiện đỉnh R kiểu Pan-Tompkins gọn nhẹ: (1) loại bỏ trôi nền bằng trung bình trượt 0,2 s, (2) lấy đạo hàm rời rạc, (3) bình phương, (4) tích phân cửa sổ trượt khoảng 40 ms, và (5) chọn đỉnh cực đại với ngưỡng thích nghi ($0,35 \times$ percentile 99 của tín hiệu tích phân) kèm chu kỳ trơ (refractory period) tối thiểu 0,25 s để loại đỉnh lặp. Sau khi thu được chuỗi vị trí đỉnh R, các khoảng R–R (giây) được tính:

$$\text{RR}_i = \frac{R_{i+1} - R_i}{f_s}, \quad (29)$$

trong đó R_i là vị trí mẫu của đỉnh R thứ i và f_s là tần số lấy mẫu. Chỉ giữ lại các khoảng R–R nằm trong dải sinh lý thai nhi (90–220 bpm, tương ứng $\text{RR} \in [60/220, 60/90]$ s) để loại bỏ các khoảng sai do nhiễu hoặc bỏ sót đỉnh. Nhịp tim thai tức thời được tính bằng trung vị (median) của các khoảng R–R hợp lệ:

$$\text{FHR}_{\text{inst}} = \frac{60}{\text{median}(\text{RR})} \quad (\text{bpm}). \quad (30)$$

Phép lấy trung vị (thay vì trung bình) giúp ước lượng bền vững hơn trước các

khoảng R–R ngoại lai. Trong hệ thống thời gian thực, giá trị FHR hiển thị được làm mượt thêm bằng bộ lọc trung bình mũ (exponential moving average — EMA) với hệ số $\alpha = 0,45$:

$$\text{FHR}_t = \alpha \cdot \text{FHR}_{\text{inst}} + (1 - \alpha) \cdot \text{FHR}_{t-1}, \quad (31)$$

nhằm triệt tiêu dao động nhịp ngắn hạn và cho giá trị ổn định trên giao diện lâm sàng.

Để đánh giá độ chính xác của ước lượng FHR, sai số tuyệt đối trung bình (MAE) giữa FHR ước lượng và FHR tham chiếu được tính trên từng cửa sổ phân tích:

$$\text{MAE}_{\text{FHR}} = \frac{1}{M} \sum_{j=1}^M \left| \text{FHR}_j^{(\text{est})} - \text{FHR}_j^{(\text{ref})} \right| \quad (\text{bpm}), \quad (32)$$

trong đó M là số cửa sổ đánh giá.

0.7 Kết luận chương

Chương này đã trình bày mô hình đề xuất KAN-WNETR cùng toàn bộ vật liệu và phương pháp thực nghiệm. Về mô hình, KAN-WNETR giữ nguyên macro-architecture chữ W của W-NETR (hai nhánh + khử đặc trưng mECG) và chỉ thay khối MLP/FFN trong mọi Transformer encoder block bằng FasterKAN — biến thể KAN sử dụng hàm cơ sở RBF kết hợp nhánh SiLU residual — nhằm tăng năng lực phi tuyến token-wise và bảo toàn hình thái fECG. Về thiết lập thực nghiệm, dữ liệu được lấy từ FECGSYNDB với chiến lược chia độc lập đối tượng, qua tiền xử lý (lọc thông dải 3–90 Hz, phân đoạn cửa sổ 992 mẫu, chuẩn hóa theo độ lệch chuẩn). Mô hình được huấn luyện với hàm mất mát Huber và cấu hình siêu tham số đã nêu; việc đánh giá dựa trên thuật toán phát hiện QRS Pan–Tompkins cùng các nhóm chỉ số phát hiện (Precision/Recall/F1/Accuracy), chất lượng tín hiệu (PSNR/SSIM/MSE) và sai số ước lượng FHR. Kết quả định lượng tương ứng được trình bày và phân tích ở Chương ??.